3 结果与讨论

Cloudra 的设计围绕反应机理研究中的两次转换展开：化学意图如何落实为具体的空间操作，局部计算结果如何共同支持一项科学结论。本节结合自主研究轨迹、局部对照和内部状态干预，分析这两次转换中信息的作用，并据此解释分子表征、几何算子、证据 DAG 与诊断反馈之间的联系。

3.1 实验体系与任务覆盖

CloudraBench 的 50 个化学问题涵盖基元转化、多步过程、竞争通道、立体化学及电子态相关判断，按 Easy、Normal、Hard 和 Impossible 分为 20、10、10 和 10 题。化学类别与研究要求共同决定任务内容。例如，电环化问题既可以要求寻找一条反应通路，也可以要求比较不同旋转方向的立体结果；同一反应物与产物表示，还可能对应不同构型之间的重排或特定电子态下的可达性问题。任务名称的语义分析中，Diels–Alder 反应与环丁烯开环分别形成跨难度层级的近邻，体现了化学主题与研究要求的交叉分布。

本节的过程分析使用完整归档的 48 次自主运行，包含 Guided、Record、Standard 和 Brief-errors 四种系统配置、四个代表性任务及每个条件下的三次重复。四个任务分别为氟离子参与的氯乙烷消除（E1）、丙二酸热脱羧（NB1）、3-甲基环丁烯开环的立体化学问题（HA1），以及涉及矩形与正方形构型的环丁二烯自重排问题（IA1）。这些任务分别要求反应中心预组织、连续步骤衔接、竞争构型比较，以及对指定势能面描述的判断。正式运行期间没有人工介入；保存的对话、工具调用、可见输出与计算产物构成过程分析的来源。从归档中提取的 6,087 条相关科学工具结果记录，用于追踪研究目标、程序返回与后续动作之间的关系。

归档运行采用 DeepSeek-v4-flash；局部诊断使用本地 Qwen3.8:27b，围绕源结构或源证据链构造配对输入。诊断分别改变分子表示、选项顺序、几何信息、证据引用或推理模式，并记录实际选择及生成 token 数。原始轨迹说明系统中的问题如何出现，配对输入用于观察特定信息如何参与判断，内部状态干预进一步追踪测量事实对选择的影响。下文沿这三层证据展开两条设计主线。

3.2 从化学意图到可靠空间操作

3.2.1 化学身份为操作提供持续参照

一次几何修改首先需要确定它作用于哪个分子、哪个原子和哪个反应中心。相同分子可以有不同的 SMILES 遍历方式；相同分子式也可以对应不同连接关系。为考察模型如何处理这些差别，我们构造了 16 对分子身份问题，覆盖相同身份、同分子式下的连接变化、连接与电荷位置变化、双键立体化学以及质子化变化。每一对交叉设置原字符串或等价改写，以及两种答案顺序，得到 64 次判断。

模型在其中 58 次作出正确判断。等价改写改变了 32 组表示配对中的 4 组语义判断，交换答案顺序改变了 32 组选项配对中的 6 组判断。后六组都重复选择字母 A。图 5 中的一对 C_5H_8 结构尤其直观：环内双键与环外双键对应不同连接方式，模型在四种条件下均回答 A，而 A 在两种顺序中分别代表“相同”与“不同”。这一结果将表示敏感性定位到实际的化学对象判断上，也说明持续研究需要保留稳定的身份参照。

Cloudra 的分子拓扑、原子映射与反应中心承担了这项职责。它们使模型在不同表述和不同构型间切换时，后续测量、片段移动及端点比较仍能指向原来声明的对象。原子对应关系还将产物端点对齐、路径插值与反应中心监测连接起来，使局部几何操作能够沿同一套化学身份继续进行。

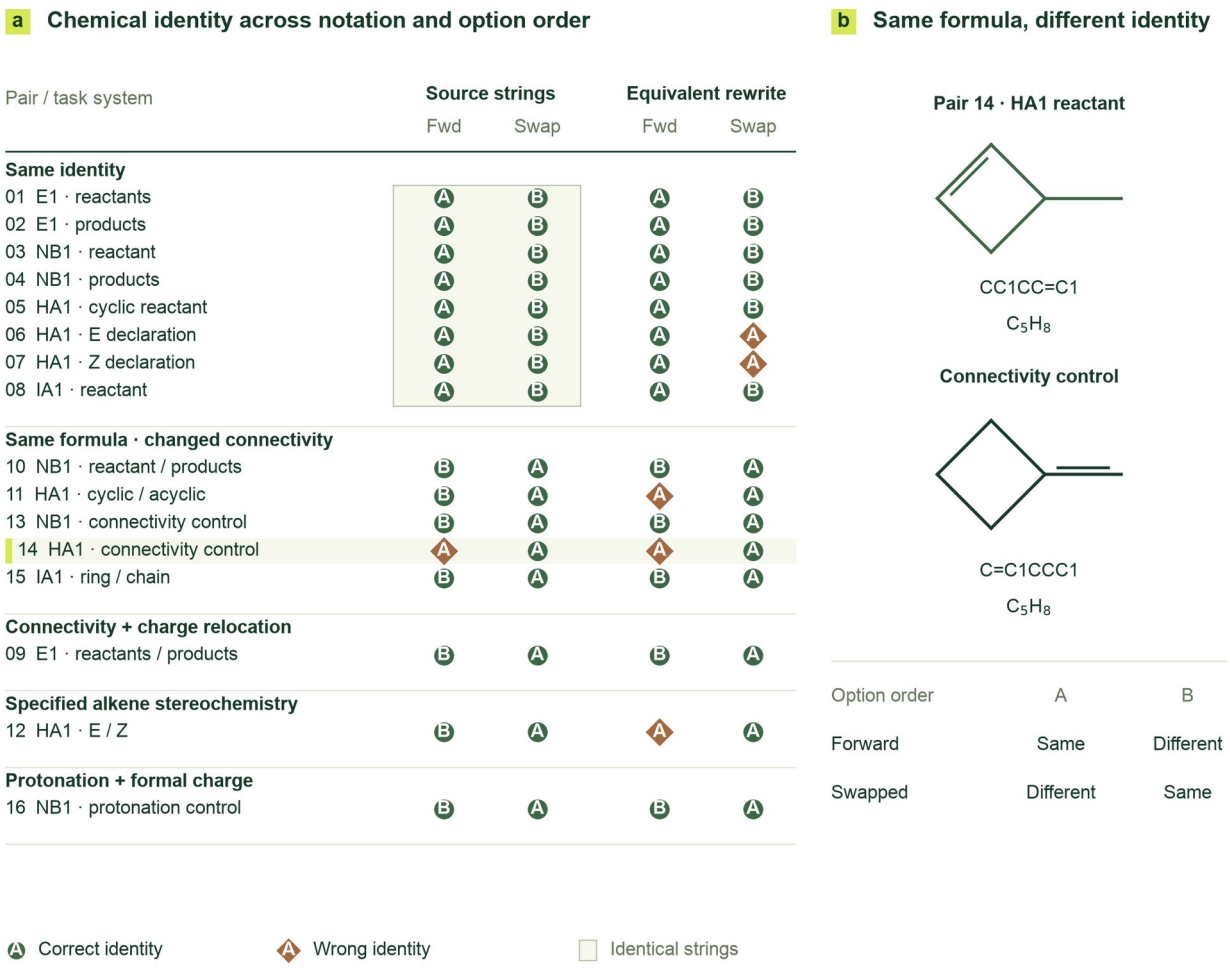


图 5. 分子表示与选项顺序下的化学身份判断。16 对分子各包含四种输入条件；圆形和菱形分别表示正确与错误，内部字母保留模型实际回答。浅色区域为相同字符串条件。右侧显示第 14 对的两种 C_5H_8 连接结构及选项含义。

3.2.2 几何测量分担反复出现的数值推理

识别研究对象之后，模型还需从坐标获得与操作有关的空间关系。我们选取 NB1 轨迹中的四个实际结构，要求比较两个指定原子间距。每个结构均交换答案顺序，并分别提供完整 XYZ 或程序测得的距离。两种信息条件进一步交叉直接作答与开启思考，形成 32 次原生聊天调用（图 6）。

直接作答时，XYZ 条件的八次响应全部选择 A，其中四次正确；提供测量距离后，八次均正确，并在选项交换后保持相同的语义答案。开启思考后，XYZ 条件得到七个正确答案，另一次在 1,024 个生成 token 时达到输出上限；该输入单独增加预算后，在 1,353 个生成 token 内得到正确答案。测量距离条件的八次回答均正确。开启思考的八组配对中，XYZ 与测量距离条件的生成 token 中位数分别为 807.5 和 86。

这些结果提示，几何判断的负担包含原子定位、数值运算和关系比较。增加推理可以完成这些局部计算，程序测量则直接提供后续判断所需的关系量。Cloudra 因而让模型以键长、键角、二面角与片段关系表达目标，由确定性算子执行坐标变化。这种分工将重复的数值工作交给程序，并使操作后的变化能够直接检查，与程序辅助语言模型的职责划分相呼应。[15] 分支拥挤描述、反应物预组织与局部片段旋转在此基础上，进一步把空间关系用于候选构型的选择和构建。

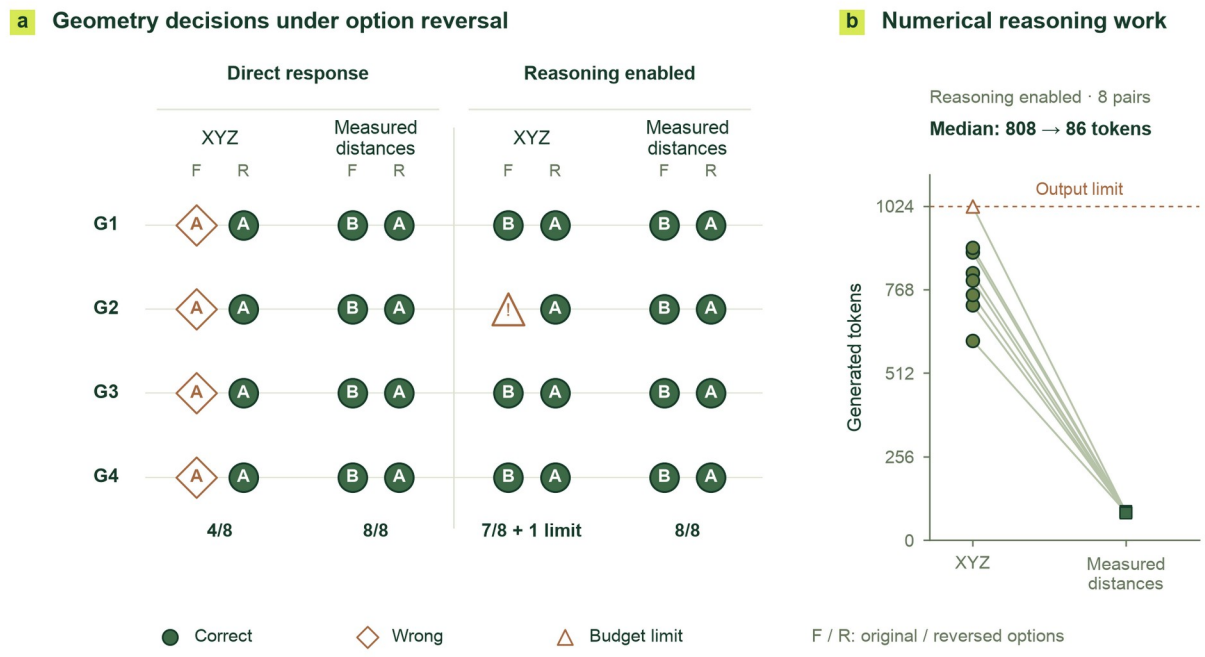


图 6. 坐标输入、程序测量与推理模式的配对比较。左侧展示四个源结构在四种条件及两种选项顺序下的回答，三角形表示达到输出预算。右侧每条连线对应开启思考时的同一结构与同一选项顺序，连接两种信息条件的实际生成 token 数。

3.2.3 反馈必须对应指定原子与几何目标

确定性执行还需要与化学意图保持对应。E1 的一条真实轨迹提供了完整例子：模型希望将转移氢 H7、C2、C3 与离去原子 Cl4 调整为接近 180° 的二面角。它围绕 C2–C3 轴分别旋转 C3 一侧片段 +120° 与 −120°，构建候选 A 和 B，并将 C3–Cl4 距离调整到 2.35 Å。默认结构报告中的代表性二面角涉及 H5，而当前目标涉及 H7。模型随后主动计算两候选的 H7–C2–C3–Cl4，获得约 59.4° 和 179.4°，并在下一次实际提交中采用候选 B。

图 7 直接由保存的候选坐标绘出沿 C2→C3 方向的 Newman 投影。候选 B 的 H7 目标角距 180° 仅 0.6°，A 的相应残差为 120.6°；H5 比较量在两候选中的残差分别为 124.2° 和 115.8°。这组数据揭示了反馈的对象依赖性：一个读数的化学意义，来自它与当前指定原子及操作目的的对应关系。

围绕同一组测量值的局部对照进一步显示了信息与动作的连接。只提供 H5 时，三种循环选项排列均请求补测 H7；加入 H7 后，三种排列均选择 B。另两组充分性配对也随目标量的加入，从需要补测转为信息充分。由此，原子映射、内坐标、片段操作和反馈可以沿一条研究动作链理解：确定目标对象，执行空间改变，测量目标量，再选择下一候选。预组织、刚体对齐与路径准备也沿用这一对应关系，将反应意图传递到后续势能面探索。

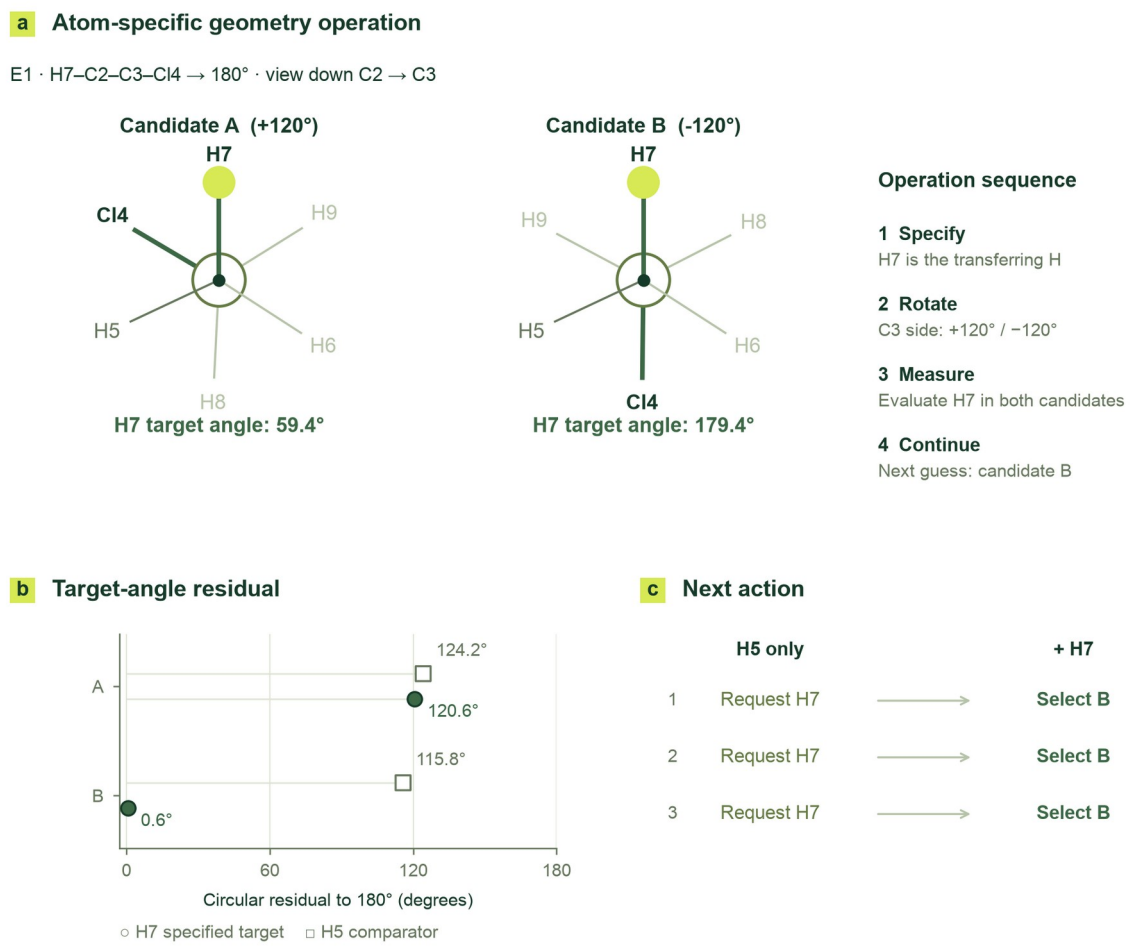


图 7. E1 中的目标一致性与候选选择。候选 A、B 的 Newman 投影由原坐标的投影方向绘制。H7 为指定目标原子；下方比较 H7 与 H5 到目标角的圆周残差，并展示三种局部选项排列中从请求目标测量到采用 B 的动作变化。

3.2.4 测量事实的内部传递影响选择

为进一步考察模型怎样使用已提供的测量值，我们在同一本地量化模型中进行了单位置激活替换。[16] 输入中的一个距离由 2.029 Å 改为 1.029 Å，另一距离保持 1.248 Å，对应的比较答案随之反转。随后把原始输入在数字 token 位置的残差状态，分别替换到改动输入的第 7、15、31 和 47 层，并读取原始事实所对应答案的全词表概率。

替换的影响随层和选项顺序变化（图 8）。在交换选项的输入中，原始事实答案 A 的概率由改动后的 0.074，在第 7 和 15 层替换后分别升至 0.956 和 0.718；第 31 和 47 层的值分别为 0.072 和 0.070。在原选项顺序中，答案 B 的概率由 0.009，在前两层替换后分别变为 0.029 和 0.015，后两层仍接近改动输入。自替换及未改变前缀位置的控制替换中，全词表 logit 差均为零。

这一内部干预将“提供测量值”推进到“测量信息怎样参与选择”的层面：指定数字位置的状态能够改变后续答案倾向，影响同时依赖于信息传递位置与答案组织方式。与行为层面的选项交换结果联系起来，这提示工具输出需要让事实、对象和待作决定相互对应。Cloudra 的结构化测量因此既是几何计算的结果，也是模型下一步研究判断的输入。

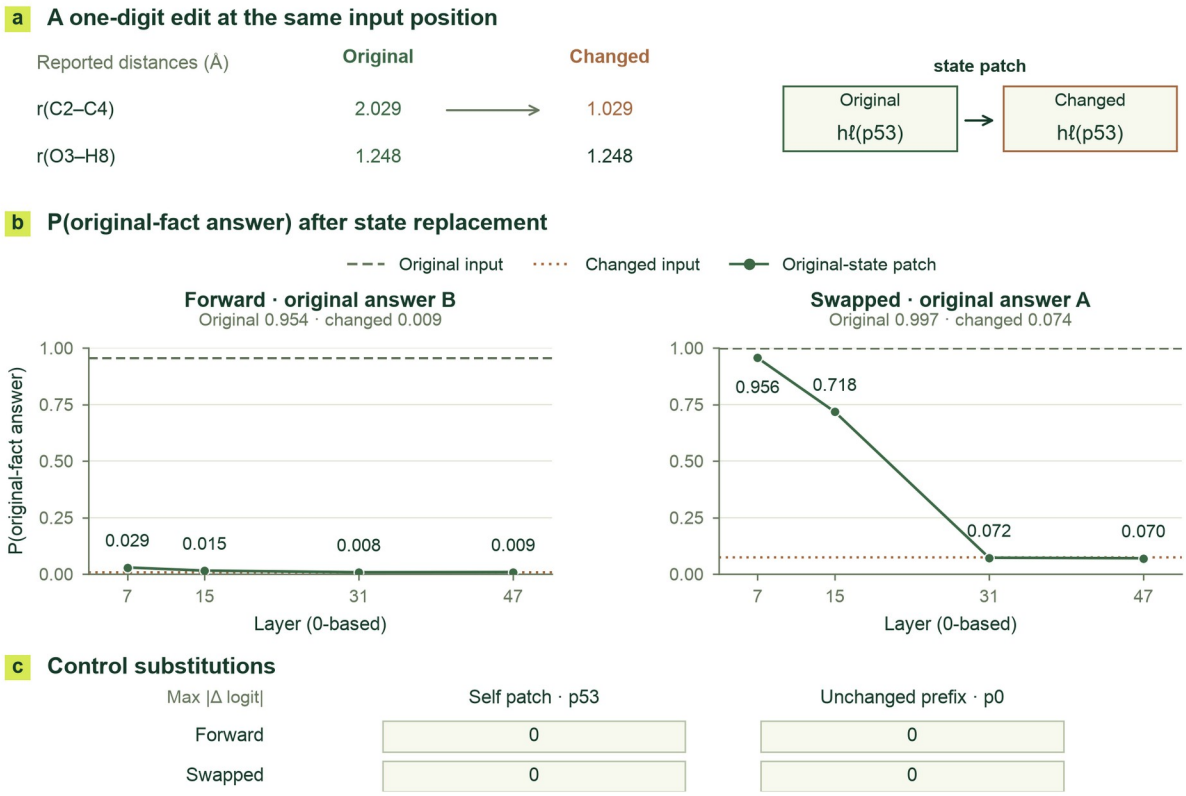


图 8. 单个测量事实的内部状态替换。上方显示距离数字的改变及残差状态替换；中间分别绘出两种选项顺序下原始事实答案的概率及两条输入基线；下方为自替换和前缀替换控制。层号与 token 位置均从零计数。

3.3 从局部计算结果到有证据的科学交付

3.3.1 DAG 保存结果之间的科学支持关系

几何对象进入计算之后，研究需要把优化结构、能量、频率与路径逐步组织成对同一反应步骤的支持。每份结果的局部有效性及其归属共同决定这条支持链：频率应对应所声明的鞍点，IRC 应从该鞍点出发，两侧末帧的优化与频率应对应相应端点。DAG 将这些关系保存在物种与基元步骤上，为不断增加的结果提供持续的研究索引。执行状态、数值收敛与科学支持分别记录，使后续研究能够据此等待计算、调整重算或继续补充证据。

我们从归档提取四条源证据链，分别构造保持关联与改变单一引用的版本，并交叉平铺表示、关联表示和两种答案顺序，得到 32 个输入。单一引用的变化分别涉及频率几何、IRC 起始几何、端点优化输入或目标物种；局部终止、收敛、能量和频率值保持不变。图 9a 以 E1 为例：将频率的几何引用从鞍点改为一个已有的端点，便改变了这份频率对当前步骤的支持关系。

关联表示的 16 次判断均正确，平铺表示的 16 次中有 14 次正确；两处错误均出现在引用已改变且选项交换的条件，分别来自 E1 与 NB1 第二步。随后选择的两条源链原生跟进中，开启思考使全部 16 次关联判断正确，包括原先两处错误。这一结果提示，明确关联可以分担模型查找与拼接计算关系的工作，也与图编码方式影响语言模型关系推理的观察相呼应。[17] 在 Cloudra 中，这种表示进一步与真实计算产物绑定，使同一物种、步骤和尝试下的科学事实能够持续累积。

3.3.2 诊断将缺口转化为具体研究动作

关联状态需要进入模型可用的反馈，才能推动修正。NB1 的一例中，完整返回已经包含阻塞原子对，但模型最初只打印整份摘要的前 2,500 个字符，该对象未进入可见输出。随后定向读取阻塞字段，模型获得相关信息，并修改同

一次尝试的反应中心，后续优化作业进入队列。这条轨迹显示，事实生成与下一步动作之间，还经过输出选择和对象定位两个环节。

另外两条轨迹体现了科学提示与操作接口的配合。Brief-errors 的 HA1 案例按实验设置移除了 IRC 端点关联的具体诊断，模型随后只更换源极小值引用，重新提交后仍保留关联缺口。Guided 的 NB1 案例中，原始检查发现零虚频，计算智能体实际看到模式错误类别；协调智能体随后补充具体的重试方案，计算智能体据此推进新的初猜与鞍点优化设置，并将改动落实到实际执行的计算定义。三例共同说明，恢复过程需要把“什么证据有问题”连接到“应该修改哪个对象或计算”。外部工具反馈支持模型修正的研究也强调了这一环节。[18]

这解释了 Cloudra 如何组织科学诊断与多智能体协作：计算智能体依据结构和路径反馈修改具体尝试，协调智能体根据这些结果继续原路线或切换候选，督导智能体结合任务要求审阅已有支持。异步调度与持久化执行保存正在推进的计算，使各角色可以在计算返回后继续围绕同一对象工作。不同角色的判断由共享对象和证据联系起来，后续计算再为下一次决定提供新的事实。

3.3.3 未完成项必须持续参与结束判断

科学交付还需要一次全局判断：现有结果是否已经满足研究要求。IA1 的真实轨迹中，DAG 报告明确保留了未满足证据项与空的豁免列表，同时已有 Supervisor 对部分计算证据的认可。模型随后仍尝试以完成状态结束研究。程序再次返回继续工作的决定，并将缺少 short_irc 的要求送回上下文；模型紧接着将结束请求改为部分完成（图 9c）。这段行为表明，局部成果、审阅意见与全局研究要求可能同时参与模型的结束决定，持续保留的科学状态为它们提供了共同参照。

明确状态也能被模型直接使用。在围绕该案例构造的 12 个权威来源对照中，模型均按现有未完成、未豁免的记录判断。只提供最新报告与提供包含 12 条原消息的历史窗口时，三个状态问题在两种答案顺序下的 12 次响应，也都保留了尚未满足的要求。DAG 因此可以作为下一轮推理的明确起点：已有支持归属于哪些对象，当前缺口是什么，下一步应继续补证还是据实提交部分结果。Supervisor 的审阅则帮助解释路线、方法与例外范围。

两条设计主线由此汇合。几何侧保存化学意图与原子、片段和目标量之间的对应，证据侧保存科学主张与计算结果、支持关系和未完成项之间的对应。内坐标使模型能够围绕可执行的空间变化推进，DAG 使这些变化产生的结果能够进入持续累积的科学判断。Cloudra 的各项设计共同服务于这一研究过程：让模型提出的目标，始终关联到可操作的对象、可观察的变化和能够支持交付的证据。

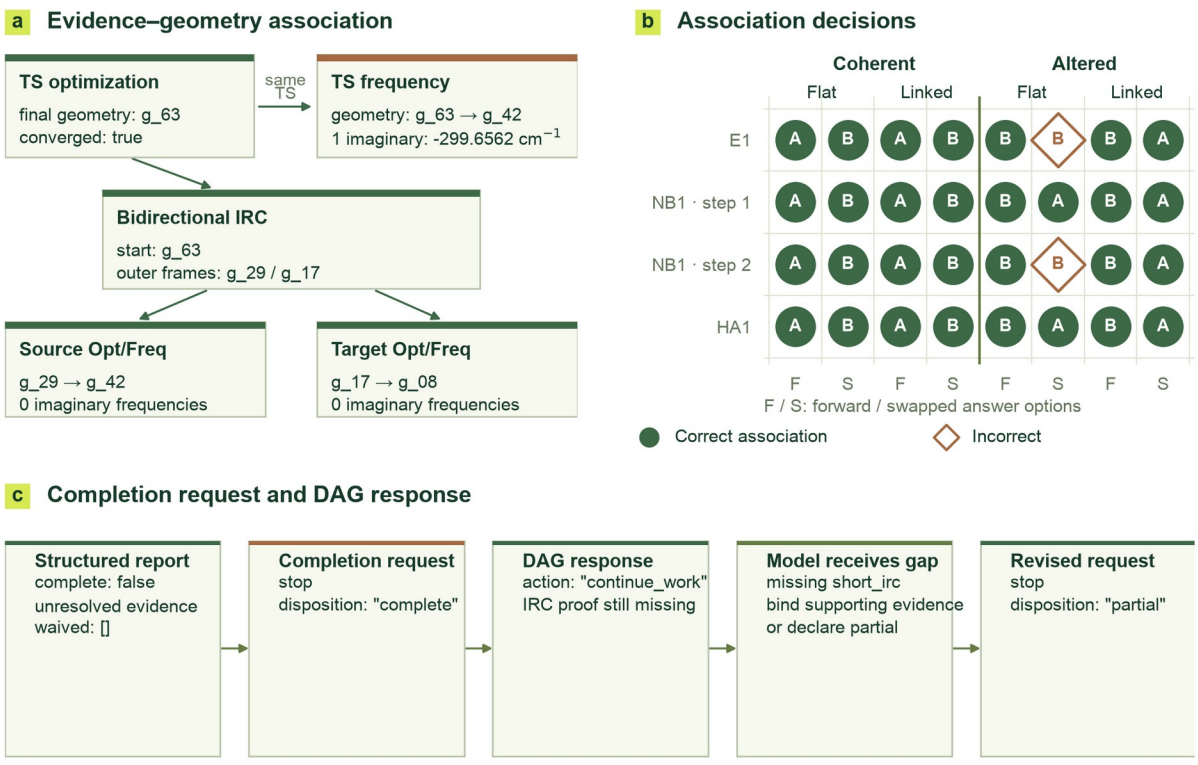


图 9. 证据关联与结束决定。a，E1 源链中的频率几何引用改变；b，四条源链在关联状态、表示方式及选项顺序交叉条件下的 32 次回答；c，原 IA1 轨迹中，从未完成报告、完成请求、DAG 反馈到部分完成请求的行为顺序。

本节参考文献

[15] Gao, L.; Madaan, A.; Zhou, S.; et al. PAL: Program-aided Language Models. Proceedings of the 40th International Conference on Machine Learning 2023, 202, 10764–10799. https://proceedings.mlr.press/v202/gao23f.html

[16] Zhang, F.; Nanda, N. Towards Best Practices of Activation Patching in Language Models: Metrics and Methods. International Conference on Learning Representations 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/06a52a54c8ee03cd86771136bc91eb1f-Abstract-Conference.html

[17] Fatemi, B.; Perozzi, B.; Halcrow, J. Talk like a Graph: Encoding Graphs for Large Language Models. International Conference on Learning Representations 2024. https://research.google/pubs/talk-like-a-graph-encoding-graphs-for-large-language-models/

[18] Gou, Z.; Shao, Z.; Gong, Y.; et al. CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing. International Conference on Learning Representations 2024. https://arxiv.org/abs/2305.11738